Séries de tempo

Aula - Outliers e Missings

Regis A. Ely

Departamento de Economia
Universidade Federal de Pelotas

10 de julho de 2020

Outliers

- Inspecionar o gráfico

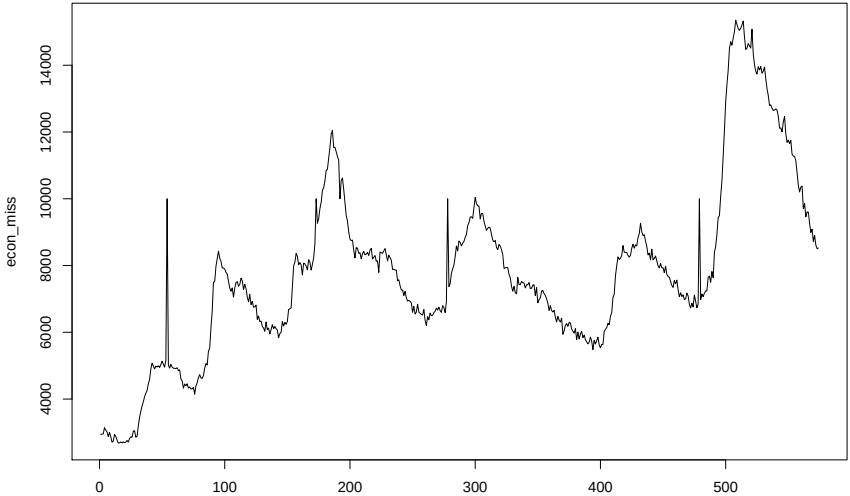

Outliers

- Investigar o motivo dos outliers
  - Olhar caso a caso
  - Se não for possível recorrer a alternativas mais automatizadas
- Alternativas:
  1. Winsorize
  2. Boxplot
  3. Separatrizes
  4. Etc...
- Se o outlier não traz nenhuma informação relevante, ele pode ser tratado como um missing

Outliers

```
library(DescTools)
econ_miss_d <- diff(econ_miss)
par(mfrow = c(2,1))
ts.plot(econ_miss)
ts.plot(cumsum(Winsorize(diff(econ_miss))))
```

Outliers

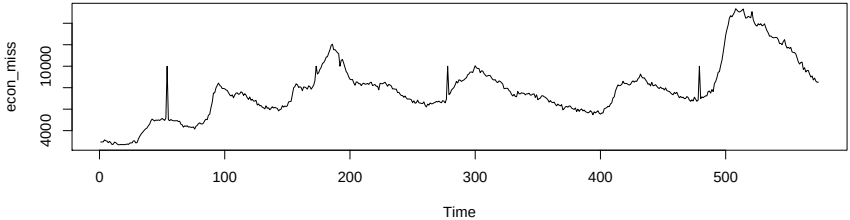
econ_miss
4000
10000
0
100
200
300
400
500
Time

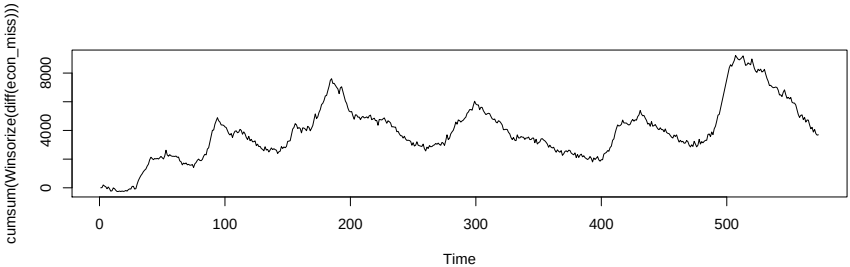
cumsum(Winsorize(diff(econ_miss)))
0
4000
8000
0
100
200
300
400
500
Time

Missings

- Inspecionar dados

```
tibble(airquality) %>%
  filter(is.na(Ozone))
```

- Inspecionar gráfico (menos visível)

```
ts.plot(airquality$Ozone)
```

Missings

- Investigar a fonte dos NAs
  - Casos tendem a ter razões semelhantes
  - Missings podem acrescentar viés nas estimações
- Alternativas:
  - Remoção: `drop_na()`
  - Imputação: média, spline, kNN, bagging, etc.
  - Interpolação: modelos ARIMA, regressões, etc.
- **Importante**: lidar com outliers antes de sair fazendo regressões

Missings

Para remover outliers podemos usar a função `drop_na()` quando especificamos os dados como um `tibble`:

```
tibble(airquality) %>%
  drop_na(Ozone)
```

Missings

Para imputar valores podemos usar a função `impute` do pacote `Hmisc`:

```
library(Hmisc)
ozone <- airquality$Ozone
ts.plot(impute(ozone, mean))
```

Missings

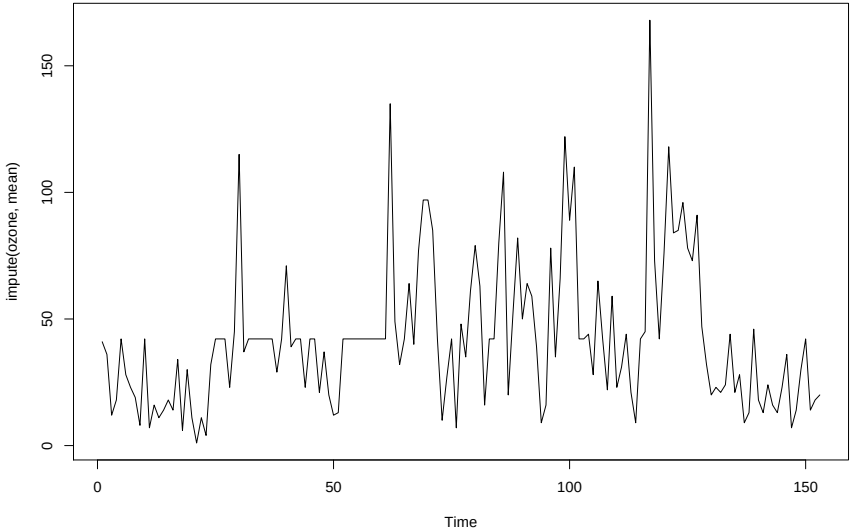

Missings

Para imputar valores usando *nearest neighbour* podemos utilizar a função `knnImputation` do pacote `DMwR`:

```
library(DMwR)
ts.plot(knnImputation(airquality)$Ozone)
```

Missings

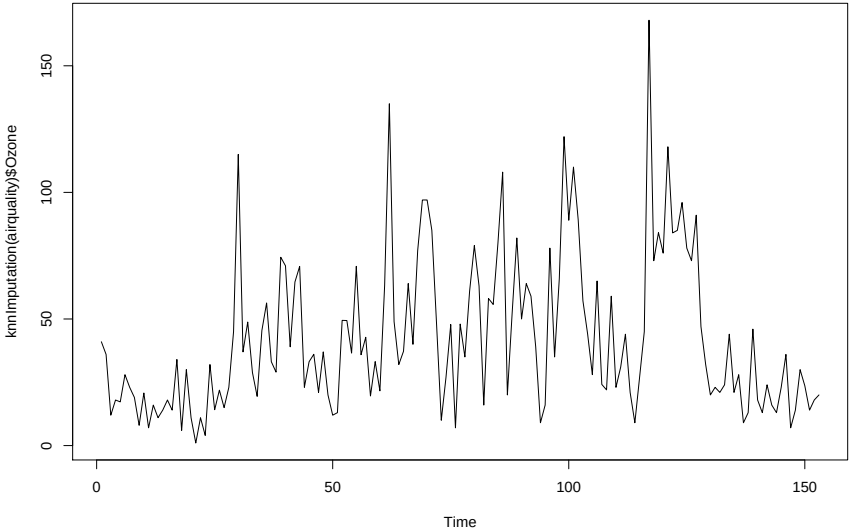
knnImputation(airquality)$Ozone
0
50
100
150
0
50
100
150
Time